

Clasificación y reconstrucción de objetos en visión biónica

Evaluación de información semántica y espacial preservada en perceptos simulados con pulse2percept
Joel Jablonski, Estanislao Molina Abeniacar

Universidad de San Andrés – Visión Artificial

1. Problema y motivación

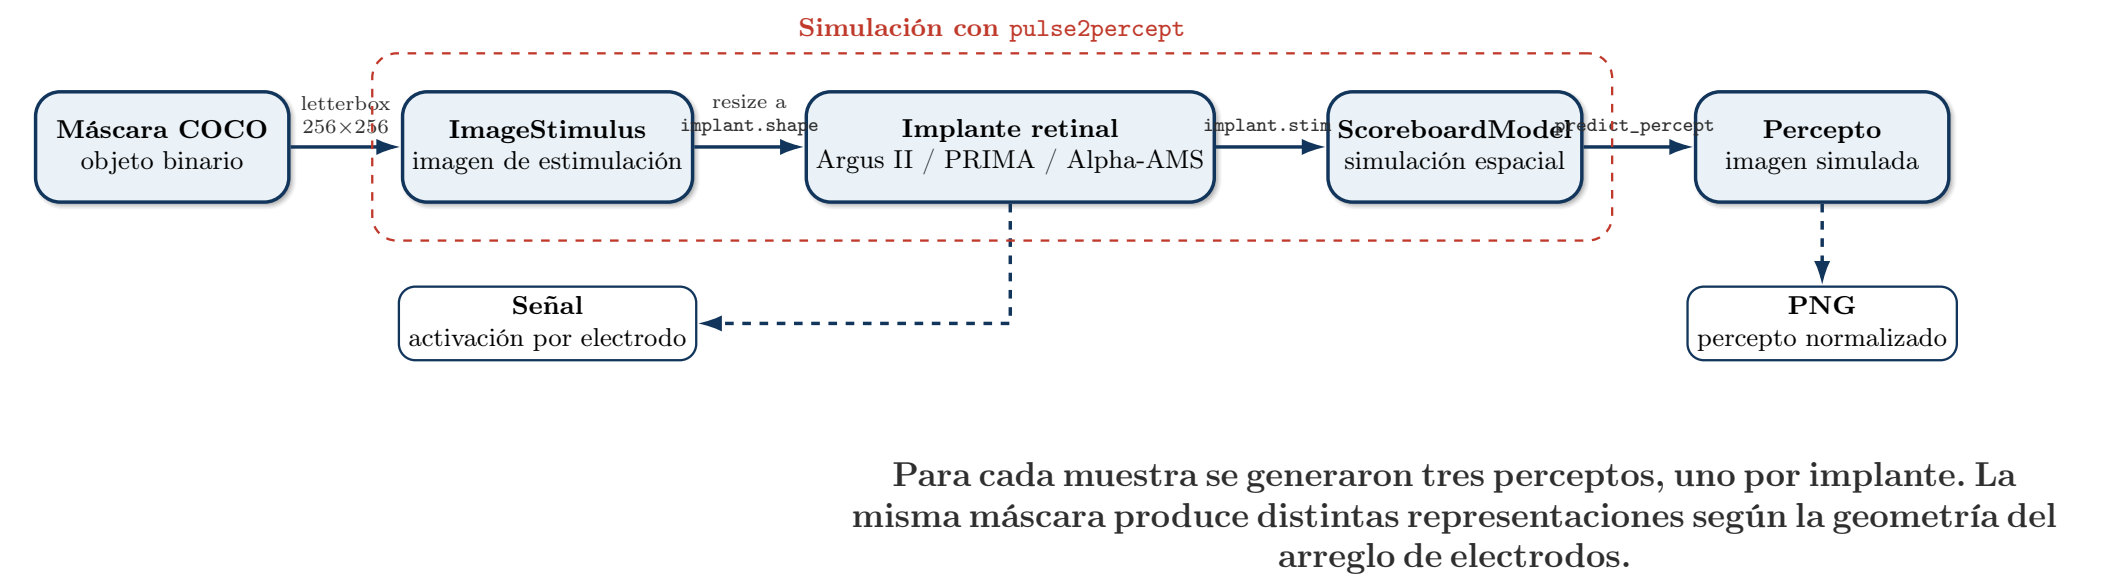
Las prótesis retinales no transmiten una imagen natural completa; generan una percepción degradada, de baja resolución y dependiente de la geometría del implante.
Motivación real. El objetivo de fondo es estudiar qué transformaciones o filtros podrían hacer que una escena sea más interpretable para una persona usuaria de una prótesis visual.
Como evaluar filtros directamente con usuarios requiere experimentos psicofísicos y métricas perceptuales, este trabajo aborda una etapa previa:

medir cuánta información útil sobrevive al pasaje por un implante simulado.

Para eso se usaron dos tareas proxy:

- **Clasificación:** mide preservación semántica.
- **Reconstrucción:** mide preservación espacial y de forma.

2. Pipeline general



Para cada muestra se generaron tres perceptos, uno por implante. La misma máscara produce distintas representaciones según la geometría del arreglo de electrodos.

Figura 1: Pipeline general: objetos segmentados de COCO se transforman en perceptos simulados y luego se evalúan mediante clasificación y reconstrucción. El flujo experimental fue:

COCO → máscara → pulse2percept → percepto

Luego, cada percepto se utilizó como entrada para:

percepto → clase y percepto → máscara reconstruida

3. Conjunto de datos y perceptos

Se trabajó con máscaras binarias de COCO para cuatro clases:

person car chair dining table

Las máscaras se normalizaron a 256×256 píxeles manteniendo aspect ratio mediante padding negro.

Clase	Muestras
person	900
car	900
chair	900
dining table	624

Se generaron perceptos para tres modelos de implante:

- Argus II
- PRIMA
- Alpha-AMS

La partición train/validación/test se realizó por sample_id, no por fila, para evitar que perceptos del mismo objeto aparezcan en splits distintos.

4. Ejemplos de perceptos




Figura 2: Ejemplos de perceptos simulados. Una misma máscara genera representaciones distintas según el implante.

pulse2percept se utilizó como herramienta de simulación controlada: no modela toda la experiencia visual de un paciente, sino la degradación perceptual asociada a distintas geometrías de implante. Esto permite comparar si distintas representaciones conservan información suficiente para reconocer o reconstruir el objeto original.


5. Clasificación de objetos

Entrada: percepto simulado.

Salida: clase del objeto.

Se compararon modelos clásicos y neuronales:

- KNN + PCA: percepto redimensionado, aplanado y clasificado por similitud.
- CNN: modelo neuronal por implante individual.
- CNN + GRU: fusión aprendida de perceptos multi-implante.



6. Resultados de clasificación

Modelo	Accuracy test
Baseline mayoría	0.271
KNN multi-implante	0.611
CNN + GRU	0.575
KNN PRIMA	0.571
KNN Alpha-AMS	0.567
CNN PRIMA	0.563
KNN Argus II	0.561
CNN Alpha-AMS	0.561
CNN Argus II	0.509

0.611
KNN
multi-implante

0.575
CNN+GRU
mejor red

0.271
baseline
mayoría




Figura 4: Matriz de confusión del mejor clasificador: KNN multi-implante.

El resultado es contraintuitivo: el modelo clásico KNN multi-implante superó a CNN+GRU. Esto sugiere que, para este tamaño de dataset, PCA + similitud directa fue más estable que entrenar una red neuronal desde cero.

7. Reconstrucción de máscaras

Entrada: percepto individual o perceptos fusionados.

Salida: máscara binaria reconstruida.

Se utilizó una arquitectura U-Net, adecuada para predicción píxel a píxel:

- el encoder extrae estructura global;
- el decoder recupera resolución espacial;
- las skip connections preservan localización y bordes.




Figura 5: U-Net de fusión: los perceptos de los tres implantes se apilan como canales de entrada y la salida es una máscara binaria.

8. Resultados de reconstrucción

Modelo	Dice	IoU	Acc. píxel
U-Net Argus II	0.883	0.835	0.986
U-Net PRIMA	0.871	0.825	0.982
U-Net Alpha-AMS	0.902	0.862	0.986
U-Net fusión	0.905	0.876	0.989

0.905
Dice
U-Net fusión

0.876
IoU
U-Net fusión

0.989
Acc. píxel
U-Net fusión




Figura 6: Reconstrucciones cualitativas: la U-Net recupera la forma global, aunque pierde bordes finos y partes pequeñas.

La reconstrucción fue más sólida que la clasificación. Sin embargo, la pixel accuracy debe interpretarse con cuidado, porque gran parte de la imagen corresponde al fondo negro. Dice e IoU son más informativas para evaluar superposición de la región del objeto.

9. Conclusiones e interpretación

- Los perceptos simulados conservan información útil, aunque degradada.
- La **fusión multi-implante** fue el mejor enfoque tanto para clasificación como para reconstrucción.
- La U-Net reconstruyó correctamente la **silueta global** de los objetos, pero perdió detalles finos.
- El KNN multi-implante superó a CNN+GRU, sugiriendo que los patrones globales de forma e intensidad fueron discriminativos.
- El trabajo no constituye una validación clínica, sino una etapa previa para comparar representaciones visuales en visión protésica simulada.

10. Uso real y trabajo futuro

Este pipeline puede servir para evaluar filtros candidatos antes de realizar pruebas con usuarios:

filtro candidato → percepto simulado → clasificación / reconstrucción

Si un filtro mejora la accuracy o el Dice, entonces preserva más información semántica o espacial.

Trabajo futuro:

- comparar filtros visuales simples: bordes, segmentación, siluetas, saliency;
- extender a imágenes RGB y escenas completas;
- evaluar secuencias de video;
- entrenar modelos surrogate diferenciables para optimización end-to-end.