

Plan de Trabajo Práctico

Encoder Semántico para Visión Prostética Simulada Asistida por Visión Artificial

1. Título del proyecto

Encoder Semántico para Visión Prostética Simulada Asistida por Visión Artificial

¿Puede la visión por computadora mejorar la utilidad de la visión prostética simulada? Un encoder semántico basado en segmentación de instancias evaluado sobre múltiples modelos de implante retinal simulados con pulse2percept.

2. Idea principal

El objetivo de este proyecto es estudiar si el preprocesamiento semántico mediante visión por computadora puede mejorar la utilidad de la información transmitida a través de un sistema de visión prostética simulado, bajo las restricciones de resolución propias de un implante retinal.

Los implantes retinales modernos presentan una limitación física fundamental: mientras que una retina sana dispone de millones de fotorreceptores, un implante como el Argus II cuenta únicamente con 60 electrodos. La imagen percibida por el cerebro es, en consecuencia, una grilla de puntos de luz difusos que permite detectar presencia de estímulos pero dificulta identificar objetos o localizarlos con precisión.

Este proyecto propone intervenir en el procesador que transforma la imagen de cámara antes de enviarla al implante. En lugar de transmitir la imagen cruda a baja resolución, se aplica primero un encoder semántico basado en segmentación de instancias que resalta los elementos relevantes de la escena y atenúa el fondo. A diferencia de la detección por bounding boxes, la segmentación de instancias produce máscaras a nivel de píxel, evitando que regiones de fondo dentro del recuadro del objeto consuman electrodos valiosos. La hipótesis es que esta intervención mejora la distinguibilidad de los objetos en la imagen simulada por **pulse2percept**, aprovechando mejor el canal de comunicación limitado que impone el implante.

El flujo principal del sistema es el siguiente:

Imagen → Segmentación de instancias → Encoder semántico → **pulse2percept** → Evaluación + Dashboard

Como salida complementaria al canal visual, el sistema incorpora síntesis de voz que anuncia los objetos detectados y su posición aproximada. Este componente no es el aporte principal del trabajo, sino una consecuencia natural del pipeline: dado que el modelo de segmentación ya identificó los objetos, esa información está disponible sin costo adicional.

3. Pregunta de investigación

La pregunta principal es:

¿El preprocesamiento semántico mediante segmentación de instancias mejora la distinguibilidad de elementos relevantes en la imagen simulada por **pulse2percept**, en comparación con la imagen sin procesar y con el realce de bordes clásico?

Las preguntas secundarias son:

¿Qué categorías de objetos conservan mejor su distinguibilidad después del proceso de simulación protética, y en qué medida depende esto del método de preprocesamiento utilizado?

¿El beneficio del preprocesamiento semántico varía según la resolución del implante?

¿Es el encoder semántico más útil cuanto menor es la resolución disponible?

4. Dataset

Se utilizará el dataset **COCO 2017**, específicamente el conjunto de validación compuesto por 5.000 imágenes anotadas en 80 categorías. Este conjunto incluye máscaras de segmentación de instancias a nivel de píxel, lo cual es fundamental para el enfoque adoptado.

Durante el desarrollo inicial del pipeline, se utilizarán directamente las máscaras de ground truth de COCO en lugar de correr inferencia en tiempo real. Esto permite validar el pipeline completo de procesamiento de forma más rápida y controlada, y desacoplar los errores del modelo de segmentación de los errores del encoder semántico. La integración del modelo de segmentación en inferencia en tiempo real se agrega en una etapa posterior.

Las clases de mayor interés para el caso de uso de orientación y navegación son:

- persona,
- silla,
- automóvil,
- autobús,
- bicicleta,
- semáforo,
- señal de stop,
- banco.

Para la parte de simulación protética se complementará con imágenes de interiores propias o del dataset SUN RGB-D, que refleja mejor los entornos de navegación cotidiana.

5. Pipeline del sistema

5.1. Etapa 1: Segmentación de instancias

Se utilizará **YOLO11n-seg** preentrenado en COCO para obtener máscaras de segmentación de instancias. A diferencia de la detección por bounding boxes, las máscaras de segmentación recortan el objeto con precisión a nivel de píxel, eliminando el ruido de fondo que quedaría encerrado dentro de un recuadro. Esto es especialmente importante en el contexto de prótesis visuales, donde cada electrodo representa un recurso escaso.

Durante la fase de desarrollo, las máscaras de ground truth de COCO reemplazan a la inferencia del modelo, permitiendo probar el pipeline completo sin depender de errores de predicción.

Como alternativa a YOLO-seg, se evaluará el uso de modelos fundacionales como **Grounding DINO** o **DINOv2**, que permiten identificar regiones relevantes de la imagen sin entrenamiento específico por clase y pueden recibir prompts de texto. Esto permitiría comparar un enfoque basado en detección explícita de objetos contra un enfoque basado en activaciones de atención.

5.2. Etapa 2: Encoder semántico

Con las máscaras de segmentación, el encoder construye una imagen modificada que enfatiza los objetos relevantes. El proceso es:

1. Asignar prioridad a cada clase segmentada (persona > vehículo > señal > mobiliario > resto).
2. Aplicar sobre las máscaras de alta prioridad técnicas de resalte: incremento de brillo, realce de contraste, marcado de bordes.
3. Atenuar o eliminar el fondo y las regiones de baja prioridad.

El espacio de diseño del encoder incluye múltiples técnicas a explorar y comparar: incremento de brillo, saturación, realce de bordes (Canny, Sobel), dilatación morfológica de las máscaras, y distintas intensidades de atenuación del fondo. Este componente es la contribución técnica central del proyecto.

5.3. Etapa 3: Simulación prostética

La imagen modificada se pasa por `pulse2percept`, que simula cómo la percibiría una persona con un implante retinal. El resultado es una imagen de fosfenos de baja resolución que constituye la salida visual del sistema.

`pulse2percept` actúa únicamente como herramienta de simulación y visualización. No recibe señales eléctricas reales ni produce output que sea input de ningún modelo adicional.

Para el procesamiento de video, se incorporará suavizado temporal de las máscaras de segmentación entre frames consecutivos, a fin de evitar el efecto de parpadeo (*flickering*) que se produce cuando las predicciones varían abruptamente entre cuadros. Este efecto es clínicamente relevante ya que puede desorientar al paciente, tal como documenta Kasowski et al. (2025).

5.4. Etapa 4: Salida auditiva (componente complementario)

En paralelo a la simulación visual, el sistema genera síntesis de voz mediante `pyttsx3` que anuncia los objetos detectados y su posición aproximada en la escena. Por ejemplo: “*persona, izquierda*”, “*semáforo, centro*”.

Este componente es secundario respecto al pipeline visual y no forma parte de la evaluación cuantitativa principal.

6. Implantes simulados

El experimento se ejecutará sobre tres configuraciones de implante disponibles en `pulse2percept`, permitiendo analizar cómo varía el beneficio del preprocesamiento semántico en función de la resolución:

Implante	Electrodos	Justificación
Argus II	60	El más documentado clínicamente. La baja resolución hace que la limitación sea claramente visible.
PRIMA	~378	Más moderno, usado en ensayos clínicos recientes (Palanker et al., 2025).
Grilla personalizada	Variable (alta)	Cota superior teórica: permite estimar hasta dónde escala el beneficio del encoder.

La hipótesis es que el beneficio del encoder semántico es inversamente proporcional a la resolución del implante: a menor resolución, mayor es la ganancia de priorizar la información antes de la simulación.

7. Rol de pulse2percept

`pulse2percept` cumple un único rol en este proyecto: **simulación y visualización protésica**.

imagen preprocesada $\rightarrow$ `pulse2percept` $\rightarrow$ percepto visual simulado (fosfenos)

El percepto simulado se utiliza exclusivamente para:

- generar las figuras comparativas del dashboard,
- calcular las métricas de evaluación cuantitativa sobre el output de la simulación.

La librería no interviene en la segmentación ni en el encoder semántico.

8. Diseño experimental

Se comparan tres condiciones de preprocesamiento sobre el mismo conjunto de imágenes y para cada uno de los tres implantes simulados:

Condición	Descripción
Baseline	Imagen original sin procesamiento previo, reducida directamente por <code>pulse2percept</code> .
Edge-enhanced	Aplicación de operadores Canny o Sobel para realce de bordes antes de la simulación protésica.
Semántico	Encoder semántico basado en máscaras de segmentación de instancias: resalte de objetos prioritarios y atenuación de fondo antes de la simulación.

Esto resulta en una grilla de $3 \times 3 = 9$ combinaciones condición–implante, lo que permite analizar tanto el efecto del preprocesamiento como el efecto de la resolución del implante de forma independiente.

9. Métricas de evaluación

Las métricas principales serán calculadas automáticamente sobre el conjunto de validación de COCO 2017.

9.1. Contraste objeto-fondo

Para cada imagen y cada condición, se calcula el ratio de brillo promedio entre la región del objeto segmentado y el resto de la imagen en el output de `pulse2percept`:

$$R = \frac{\bar{I}_{\text{objeto}}}{\bar{I}_{\text{fondo}}}$$

Un valor de R mayor indica que el objeto es más distinguible del fondo en la imagen simulada. A diferencia de la versión basada en bounding boxes, aquí la región del objeto corresponde a la máscara de segmentación, lo que excluye el fondo interior al recuadro.

9.2. IoU simulado

Dado que `pulse2percept` produce mapas de fosfenos continuos y borrosos, se requiere una estrategia de umbralización para binarizar el output antes de calcular áreas. Se define la región de contraste suficiente como el conjunto de píxeles con brillo superior a un umbral τ , elegido como percentil 75 del brillo en la imagen simulada. Se calcula el IoU entre dicha región y la máscara de segmentación original:

$$\text{IoU} = \frac{|\text{región contraste} \cap \text{máscara GT}|}{|\text{región contraste} \cup \text{máscara GT}|}$$

9.3. SSIM

Como métrica complementaria que no requiere umbralización, se calculará el *Structural Similarity Index* (SSIM) entre el output de `pulse2percept` bajo cada condición y una referencia ideal construida a partir de la máscara de segmentación de ground truth. SSIM es más robusto para comparar texturas continuas y captura degradación perceptual de forma más fiel que métricas basadas en píxeles individuales.

9.4. Análisis por clase e implante

Se reportarán las tres métricas desagregadas por clase de objeto y por implante simulado, permitiendo identificar qué categorías y qué configuraciones se benefician más del preprocesamiento semántico.

9.5. Validación perceptual (complementaria)

Se realizará una evaluación cualitativa informal en la que observadores sin contexto previo intentarán identificar el objeto principal en cada condición. Los resultados se reportarán como evidencia complementaria a las métricas automáticas, con la aclaración explícita de que no constituyen un experimento clínico controlado.

10. Líneas base

10.1. Baseline 1: imagen sin procesar

Imagen original reducida directamente a la resolución del implante sin ninguna intervención. Representa el estado actual de los sistemas de implante sin preprocesamiento inteligente.

10.2. Baseline 2: realce de bordes clásico

Aplicación de operadores Canny o Sobel antes de la simulación. Representa el enfoque estándar de preprocesamiento para prótesis visuales documentado en la literatura.

10.3. Cota superior: imagen original sin degradación

Para estimar la pérdida de información introducida por la simulación protética, se reportará la distinguibilidad de objetos en la imagen original sin pasar por `pulse2percept`.

11. Stack tecnológico

- **Python:** lenguaje principal del proyecto.
- **OpenCV:** procesamiento de imágenes y operadores de borde.

- **Ultralytics YOLO11n-seg**: segmentación de instancias preentrenada en COCO.
- **Grounding DINO / DINOv2**: modelos fundacionales para segmentación sin entrenamiento explícito (evaluación comparativa).
- **pulse2percept**: simulación de percepción prostética.
- **pyttsx3**: síntesis de voz para salida auditiva.
- **scikit-image**: cálculo de SSIM y métricas de imagen.
- **NumPy**: cálculo de métricas.
- **Streamlit**: dashboard comparativo interactivo.

12. Paquetes de trabajo

12.1. Paquete de trabajo 1: configuración del entorno y datos

Tareas:

- instalar y verificar **pulse2percept** en el entorno de trabajo,
- descargar el validation set de COCO 2017 con máscaras de segmentación,
- construir el data loader que devuelva imagen, máscara GT y etiquetas de clase,
- verificar la carga correcta de máscaras de instancia para las clases de interés.

Entregable: pipeline de carga de datos funcional con máscaras de segmentación de ground truth.

12.2. Paquete de trabajo 2: encoder semántico con ground truth

Tareas:

- implementar el encoder semántico usando máscaras GT de COCO (sin inferencia de modelo),
- definir la jerarquía de prioridad de clases,
- explorar y comparar distintas técnicas de resalte sobre las máscaras,
- integrar la síntesis de voz como salida complementaria,
- verificar outputs visuales sobre imágenes de muestra.

Entregable: módulo de encoder semántico validado con ground truth.

12.3. Paquete de trabajo 3: integración del modelo de segmentación

Tareas:

- integrar YOLO11n-seg en inferencia sobre imágenes de COCO,
- comparar las máscaras predichas contra el ground truth,
- evaluar Grounding DINO como alternativa fundacional,
- conectar la salida del modelo al encoder semántico.

Entregable: pipeline completo con segmentación en inferencia.

12.4. Paquete de trabajo 4: simulación protética multi-implante

Tareas:

- integrar `pulse2percept` con Argus II, PRIMA y grilla personalizada,
- aplicar la simulación sobre las tres condiciones experimentales para cada implante,
- implementar suavizado temporal de máscaras para procesamiento de video,
- generar figuras comparativas para las 9 combinaciones condición-implante.

Entregable: pipeline de simulación protética completo para las nueve condiciones.

12.5. Paquete de trabajo 5: evaluación cuantitativa

Tareas:

- implementar el cálculo de contraste objeto-fondo (R) sobre máscaras de segmentación,
- implementar el IoU simulado con umbralización por percentil,
- implementar SSIM contra referencia ideal,
- procesar el conjunto de validación de COCO bajo las nueve condiciones,
- agregar resultados por condición, implante y clase.

Entregable: tablas de métricas por condición, implante y clase de objeto.

12.6. Paquete de trabajo 6: dashboard y demo

Tareas:

- implementar el dashboard comparativo en Streamlit,
- integrar entrada de imagen estática y video en tiempo real,
- mostrar las salidas de las tres condiciones en paralelo para el implante seleccionado,
- preparar demo para presentación oral.

Entregable: aplicación interactiva funcional para demostración.

12.7. Paquete de trabajo 7: análisis de resultados e informe

Tareas:

- comparar las nueve condiciones sobre las métricas principales,
- analizar el efecto de la resolución del implante sobre el beneficio del encoder,
- analizar qué clases se benefician más del preprocesamiento semántico,
- inspeccionar ejemplos cualitativos de aciertos y fallos,
- redactar el informe técnico.

Entregable: informe técnico con metodología, resultados, discusión y limitaciones.

13. Alcance del proyecto

La primera versión del proyecto no incluirá:

- entrenamiento de ningún modelo de detección o segmentación desde cero,
- diseño manual de pulsos eléctricos ni modificación de `pulse2percept`,
- señales reales de EEG, MEG o implantes físicos,
- experimento clínico controlado con personas con baja visión,
- estimación de profundidad o uso de cámara estéreo.

El alcance central es:

Imagen $\rightarrow$ Máscaras GT / YOLO11n-seg $\rightarrow$ Encoder semántico $\rightarrow$ `pulse2percept` $\rightarrow$ Evaluación cuantitativa

14. Extensiones futuras

14.1. Encoder aprendido optimizado para el espacio prostético

Una extensión natural es entrenar un modelo de segmentación cuya función de pérdida no minimice el error en la imagen original sino la pérdida de distinguibilidad en el output de `pulse2percept`. El desafío técnico central es que `pulse2percept` no es diferenciable, lo que requeriría una aproximación diferenciable del simulador o estrategias de optimización de caja negra, siguiendo la línea de trabajo de Granley et al. (2022).

14.2. Modelo recurrente sobre señales de estimulación

Siguiendo la sugerencia del primer profesor y la línea de trabajo del *in silico* framework, una extensión posible es entrenar una red que imite a `pulse2percept` y luego combinar ambos modelos para optimizar el desempeño de clasificación sobre las señales simuladas. Alternativamente, entrenar directamente un modelo recurrente (GRU o LSTM) que clasifique segmentos de video a partir de las señales de estimulación generadas, sin pasar por la imagen de fosfenos.

14.3. Incorporación de datasets de escena interior

Para profundizar en el caso de uso de navegación, incorporar ADE20K o SUN RGB-D como datasets de evaluación complementarios, con énfasis en clases como puerta, escalera, pared y suelo transitable.

15. Cronograma tentativo

15.1. Semanas 1–2: configuración y datos

- verificar instalación de `pulse2percept`,
- configurar COCO 2017 validation set con máscaras de segmentación,
- construir data loader con máscaras GT,
- primeras pruebas de simulación con Argus II.

15.2. Semanas 3–4: encoder semántico con ground truth

- implementar encoder semántico usando máscaras GT,
- explorar técnicas de resalte y atenuación,
- integrar síntesis de voz,
- verificar pipeline completo GT $\rightarrow$ encoder $\rightarrow$ pulse2percept.

15.3. Semanas 5–6: integración del modelo de segmentación

- integrar YOLO11n-seg en inferencia,
- evaluar Grounding DINO como alternativa,
- conectar al encoder semántico y verificar outputs.

15.4. Semanas 7–8: simulación multi-implante

- integrar PRIMA y grilla personalizada,
- implementar suavizado temporal para video,
- generar outputs para las nueve combinaciones condición–implante.

15.5. Semanas 9–10: evaluación cuantitativa

- implementar contraste objeto-fondo, IoU simulado y SSIM,
- procesar el conjunto de validación,
- agregar resultados por condición, implante y clase.

15.6. Semanas 11–12: dashboard, análisis e informe

- implementar dashboard en Streamlit,
- análisis de resultados y casos cualitativos,
- redacción del informe técnico,
- preparación de slides para presentación oral.

16. Consideraciones éticas

Este proyecto opera estrictamente en el plano de la simulación computacional. No constituye un tratamiento médico ni un dispositivo clínico. No se realizarán experimentos con personas con baja visión sin supervisión y aprobación ética correspondiente. Los resultados no deben interpretarse como evidencia de eficacia clínica de ningún sistema de implante retinal.

17. Resumen final

desarrolla y evalúa un pipeline de visión por computadora que optimiza la información enviada a un simulador de implante retinal, mejorando la distinguibilidad de objetos relevantes para la orientación y navegación.

El sistema segmenta instancias mediante YOLO11n-seg preentrenado en COCO (o máscaras de ground truth en la fase de desarrollo), construye una representación semántica simplificada que enfatiza los elementos de alta prioridad mediante máscaras a nivel de píxel, y simula la percepción resultante mediante **pulse2percept** sobre tres modelos de implante (Argus II, PRIMA, grilla personalizada). Se comparan tres condiciones de preprocesamiento mediante métricas de contraste objeto-fondo, IoU simulado y SSIM, desagregadas por condición, implante y clase de objeto.

La contribución principal es la evaluación sistemática de si el preprocesamiento semántico basado en segmentación de instancias mejora la utilidad de la información disponible dentro del canal de muy baja capacidad que impone un implante retinal simulado, y cómo ese beneficio varía en función de la resolución del implante.

Imagen $\rightarrow$ YOLO11n-seg / GT $\rightarrow$ Encoder semántico $\rightarrow$ **pulse2percept** $\rightarrow$ Contraste | IoU | SSIM $\times$ {3 implantes}

Referencias

- [1] Beyeler, M., Nanduri, D., Weiland, J. D., Rokem, A., Boynton, G. M., & Fine, I. (2019). A model of ganglion axon pathways accounts for percepts elicited by retinal implants. *Scientific Reports*, 9(1), 1–11.
- [2] pulse2percept documentation. <https://pulse2percept.readthedocs.io/>
- [3] Han, N., SLyon, A., Beyeler, M. (2021). Deep Learning–Based Scene Simplification for Bionic Vision. *IEEE EMBC Workshop on Emerging Technologies for Neural Interfaces*.
- [4] Sánchez-García, A., et al. (2020). Semantic and structural image segmentation for prosthetic vision. *PLOS ONE*.
- [5] Kasowski, M., et al. (2025). Static or Temporal? Semantic Scene Simplification to Aid Way-finding in Immersive Simulations of Bionic Vision. *Investigative Ophthalmology & Visual Science*.
- [6] Elnabawy, R., et al. (2022). A YOLO-based object simplification approach for visual prostheses. *IEEE International Symposium on Computer-Based Medical Systems (CBMS)*.
- [7] Lin, T.-Y., et al. (2014). Microsoft COCO: Common Objects in Context. *European Conference on Computer Vision (ECCV)*.
- [8] Ultralytics YOLO documentation. <https://docs.ultralytics.com/tasks/detect/>
- [9] Palanker, D., et al. (2025). Subretinal photovoltaic implant to restore vision in geographic atrophy. *New England Journal of Medicine*.